



ChatGPT'ye Giden

2017-2022 Dönemindeki Kritik Sıramalar, Maliyet Analizi ve
Yol Evrim



2017-2022: 3 Kritik

Sıçrama


Yapay zekanın kaderini değiştiren ve günümüz LLM devrimini başlatan 5 yıllık serüven.

1. Transformer Mimarisi (2017)

Attention Is All You Need

Google arařtırmacılarının yayımladıđı bu ikonik makale, dönemin standartları olan ardışık işleme dayalı RNN ve LSTM mimarilerini tahtından etti.

Kendi Kendine Dikkat (Self-Attention) mekanizması sayesinde tüm cümlelerin tek seferde paralel işlenmesine olanak tanındı. Bu gelişme, hesaplama süresini düşürürken devasa boyutlardaki modellerin eğitilebilmesinin önünü açan en kritik adımdı.



2. Pre-training Dönemi (2018)

Üretken Ön Eğitim Devrimi


OpenAI, GPT-1 (Generative Pre-trained Transformer) ile yapay zeka eğitim paradigmasını tamamen değiştirdi. Etiketli verilere olan bağımlılık ortadan kalktı.

Modelin, devasa boyutlardaki etiketsiz internet metinleriyle denetimsiz (unsupervised) olarak **ön eğitime** tabi tutulması ve ardından belirli görevler için **ince ayar (fine-tuning)** yapılması yaklaşımı tüm endüstri için bir standart haline geldi.

Functional roles of the global workspace

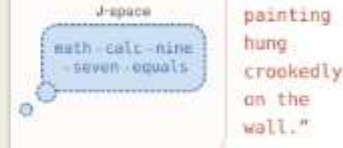
Verbal report

What are you thinking about?



Directed modulation

Compute $3^2 - 2$ while writing "The old painting hung crookedly on the wall."




Internal reasoning

What color is the planet fourth from the sun?



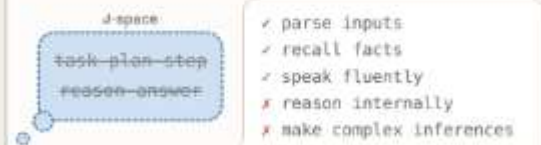
Flexible generalization

What is the capital of France?



Selectivity

(a battery of tasks)



3. **RLHF** & Dev Ölçek (2020-22)

İnsan Odaklı Hizalama

Öncelikle GPT-3 ile 175 milyar parametrenin getirdiği üstün kapasite (Few-shot yeteneği) keşfedildi. Ancak model hala kontrol edilemezdi ve asıl devrim hizalamada yaşandı.

İnsan Geri Bildirimli Takviyeli Öğrenme (RLHF) tekniği kullanılarak InstructGPT ve ardından ChatGPT geliştirildi. Bu adım, modelin çıktılarını zararsız, yararlı ve insan diyalog yapısına tam uyumlu hale getirdi.





Maliyet Analizi ve Optimizasyon

Geniş ölçekli uygulamalarda sürdürülebilirlik ve altyapı maliyetlerinin yönetimi.

Günde 1 Milyon İstek Senaryosu



Maliyet (Inference) Yüğü

- ▶ **İşlem Hacmi:** Günde 1M istek (Ort. 1000 token/istek) = Günde ~1 Milyar Token.
- ▶ **Bulut API Maliyeti:** Sektör standardı modeller (GPT-3.5 vb.) için günlük ortalama \$500 - \$1.500 arası fatura.
- ▶ **Self-Hosted GPU:** LLaMA 70B dengi bir model için 8x A100 sunucu kümesi kiralamanın günlük operasyonel maliyeti yaklaşık ~\$800 civarındadır.



Optimizasyon Önerileri

- ▶ **Semantic Caching:** Sık sorulan aynı/benzer bağlamdaki soruları API'ye ya da GPU'ya göndermeden bellekten yanıtlayarak maliyeti düşürme.
- ▶ **Nicemleme (Quantization):** Ağırlıkları FP16'dan 8-bit veya 4-bit'e indirgeyerek (AWQ/GPTQ) bellek (VRAM) kullanımını ve sunucu ihtiyacını azaltma.
- ▶ **Spesifik Modeller:** Her iş için devasa modeller yerine, belirli görevler için "Fine-tune" edilmiş daha küçük modeller (örn. 8B parametrelili) kullanma.



Evrimsel Bağlantı



Word2vec kelimelere matematiksel bir uzay kazandırdı, Transformer bu kelimelerin cümle içindeki karmaşık bağlamını çözdü ve ChatGPT tüm bu ağı akıcı, insan benzeri bir diyaloga dönüştürdü.





Dinlediğiniz İçin Teşekkürler.

Ahmet AYDUĞAN
Monitoring & DevOps